# СОДЕРЖАНИЕ

ВВЕДЕНИЕ1 ПОСТАНОВКА ЗАДАЧИ	2		
	3		
2 ПОРЯДОК ВЫПОЛНЕНИЯ	5		
3 ГРАММАТИКА МОДЕЛЬНОГО ЯЗЫКА			
		СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ	16
		ПРИЛОЖЕНИЯ	17

## **ВВЕДЕНИЕ**

Несмотря на более чем полувековую историю вычислительной техники, рождение теории формальных языков ведет отсчет с 1957 года. В этот год американский ученый Джон Бэкус разработал первый компилятор языка Фортран. Он применил теорию формальных языков, во многом опирающуюся на работы известного ученого-лингвиста Н. Хомского — автора классификации формальных языков. Хомский в основном занимался изучением естественных языков, Бекус применил его теорию для разработки языка программирования. Это дало толчок к разработке сотен языков программирования.

Несмотря на наличие большого количества алгоритмов, позволяющих автоматизировать процесс написания транслятора для формального языка, создание нового языка требует творческого подхода. В основном это относится к синтаксису языка, который, с одной стороны, должен быть удобен в прикладном программировании, а с другой, должен укладываться в область контекстно-свободных языков, для которых существуют развитые методы анализа

Основы теории формальных языков и практические методы разработки распознавателей формальных языков составляют неотъемлемую часть образования современного инженера-программиста.

Целью данной курсовой работы является:

- освоение основных методов разработки распознавателей формальных языков на примере модельного языка программирования;
- приобретение практических навыков написания транслятора языка программирования;
- закрепление практических навыков самостоятельного решения инженерных задач, умения пользоваться справочной литературой и технической документацией

## 1 ПОСТАНОВКА ЗАДАЧИ

Разработать распознаватель модельного языка программирования согласно заданной формальной грамматике.

Распознаватель представляет собой специальный алгоритм, позволяющий вынести решение и принадлежности цепочки символов некоторому языку.

Распознаватель можно схематично представить в виде совокупности входной ленты, читающей головки, которая указывает на очередной символ на ленте, устройства управления (УУ) и дополнительной памяти (стек).

Конфигурацией распознавателя является:

- состояние УУ;
- содержимое входной ленты;
- положение читающей головки;
- содержимое дополнительной памяти (стека).

Трансляция исходного текста программы происходит в несколько этапов. Основными этапами являются следующие:

- лексический анализ;
- синтаксический анализ;
- семантический анализ;
- генерация целевого кода.

Лексический анализ является наиболее простой фазой и выполняется с помощью регулярной грамматики. Регулярным грамматикам соответствуют конечные автоматы, следовательно, разработка и написание программы лексического анализатора эквивалентна разработке конечного автомата и его диаграммы состояний (ДС).

Синтаксический анализатор строится на базе контекстно-свободных (КС) грамматик. Задача синтаксического анализатора — провести разбор текста программы и сопоставить его с формальным описание языка.

Семантический анализ позволяет учесть особенности языка программирования, которые не могут быть описаны правилами КСграмматики.

## К таким особенностям относятся:

- обработка описаний;
- анализ выражений;
- проверка правильности операторов.

Обработки описаний позволяет убедиться в том, что каждая переменная в программе описана и только один раз.

Анализ выражений заключается в том, чтобы проверить описаны ли переменные, участвующие в выражении, и соответствуют ли типы операндов друг другу и типу операции.

Этапы синтаксического и семантического анализа обычно можно объединить.

## 2 ПОРЯДОК ВЫПОЛНЕНИЯ

- 1. В соответствии с номером варианта составить описание модельного языка программирования в виде правил вывода формальной грамматики;
- 2. Составить таблицу лексем и нарисовать диаграмму состояний для распознавания и формирования лексем языка;
- 3. Разработать процедуру лексического анализа исходного текста программы на языке высокого уровня;
- 4. Разработать процедуру синтаксического анализа исходного текста методом рекурсивного спуска на языке высокого уровня;
- 5. Построить программный продукт, читающий текст программы, написанной на модельном языке, в виде консольного приложения;
- 6. Протестировать работу программного продукта с помощи серии тестов, демонстрирующих все основные особенности модельного языка программирования, включая возможные лексические и синтаксические ошибки.

## 3 ГРАММАТИКА МОДЕЛЬНОГО ЯЗЫКА

Согласно индивидуальному варианту задания на курсовую работу грамматика языка включает следующие синтаксические конструкции:

- <onepaции\_группы\_отношения>::= NE | EQ | LT | LE | GT | GE
- <операции\_группы\_сложения>::= plus | min | or
- <onepaции\_группы\_умножения>::= mult | div | **and**
- <унарная операция>::=~
- <программа>::= **program var** <описание> **begin** <оператор> {; <оператор>} **end**.
  - <oписание>::= {<идентификатор> {, <идентификатор> } : <тип> ;}
  - <TU∏>∷= integer | real | boolean
- <оператор>::= <составной> | <присваивания> | <условный> | <фиксированного\_цикла> | <условного\_цикла> | <вывода>
- 1) <составной>::= «[» <оператор> { ( : | перевод строки) <оператор> } «]»
  - <присваивания>::= <идентификатор> as <выражение>
  - <ycловный>::= **if** <выражение> **then** <oператор> [ **else** <oператор>]
- <фиксированного\_цикла>::= for <присваивания> to <выражение>  $\mathbf{do}$  <оператор>
  - <ycловного\_цикла>::= **while** <выражение> **do** <oператор>
  - <ввода>::= **read** «(»<идентификатор> {, <идентификатор> } «)»
  - <вывода>::= write «(»<выражение> {, <выражение> } «)»
- Многострочные комментарии в программе (шестая цифра варианта)?
- <выражение>::= <операнд>{<операции\_группы\_отношения> <операнд>}
- <операнд>::= <слагаемое> {<операции\_группы\_сложения> <слагаемое>}
- <слагаемое>::= <множитель> {<операции\_группы\_умножения> <множитель>}

- <множитель>::=<идентификатор><логическая\_константа> |
  - <унарная\_операция> <множитель> | «(»<выражение>«)»
  - <число>::= <целое> | <действительное>
  - <логическая\_константа>::= true | false
  - <идентификатор>::= <буква> {<буква> | <цифра>}
- <буква>::= A | B | C | D | E | F | G | H | I | J | K | L | M | N | O | P | Q | R |
  S | T | U | V | W | X | Y | Z | a | b | c | d | e | f | g | h | i | j | k | l | m | n | o | p | q | r | s | t |
  u | v | w | x | y | z
  - <цифра>::= 0 | 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 | 9
  - <целое>::= <двоичное> | <восьмеричное> | <десятичное> |
  - <шестнадцатеричное>
  - <двоичное $>::= {/0 | 1/} (B | b)$
  - <восьмеричное>::= {/ 0 | 1 | 2 | 3 | 4 | 5 | 6 | 7 /} (O | о)
  - <десятичное>::= {/ <цифра> /} [D | d]
- <шестнадцатеричное>::= <цифра> {<цифра> | A | B | C | D | E | F | а | b | c | d | e | f} (H | h)
  - <действительное>::= <числовая\_строка> <порядок> |
  - <числовая\_строка>] . <числовая\_строка> [порядок]
  - <числовая\_строка>::= {/ <цифра> /}
  - <порядок>::= ( E | e )[+ | -] <числовая\_строка>

Здесь для записи правил грамматики используется форма Бэкуса-Наура (БНФ). В записи БНФ левая и правая части порождения разделяются символом "::=", нетерминалы заключены в угловые скобки, а терминалы – просто символы, используемые в языке. Жирным выделены терминалы, представляющие собой ключевые слова языка.

## 4 РАЗРАБОТКА ЛЕКСИЧЕСКОГО АНАЛИЗАТОРА

Лексический анализатор — подпрограмма, которая принимает на вход исходный текст программы и выдает последовательность лексем — минимальных элементов программы, несущих смысловую нагрузку.

В модельном языке программирования выделяют следующие типы лексем:

- ключевые слова;
- ограничители;
- числа;
- идентификаторы.

При разработке лексического анализатора, ключевые слова и ограничителя известны заранее, идентификаторы и числовые константы – вычисляются в момент разбора исходного текста

Для каждого типа лексем предусмотрена отдельная таблица. Таким образом, внутреннее представление лексемы — пара чисел (n, k), где n — номер таблицы лексем, k — номер лексемы в таблице.

Кроме того, в исходном коде программы кроме ключевых слов, идентификаторов и числовых констант может находиться произвольное число пробельных символов («пробел», «табуляция», «перенос строки», «возврат каретки») и комментариев, заключенных в фигурные скобки.

Лексический анализ текста проводится по регулярной грамматике. Известно, что регулярная грамматика эквивалентна конечному автомату, следовательно, для написания лексического анализатора необходимо построить диаграмму состояний, соответствующего конечного автомата (рис. 1).

Исходный код лексического анализатора приведен в Приложении А.

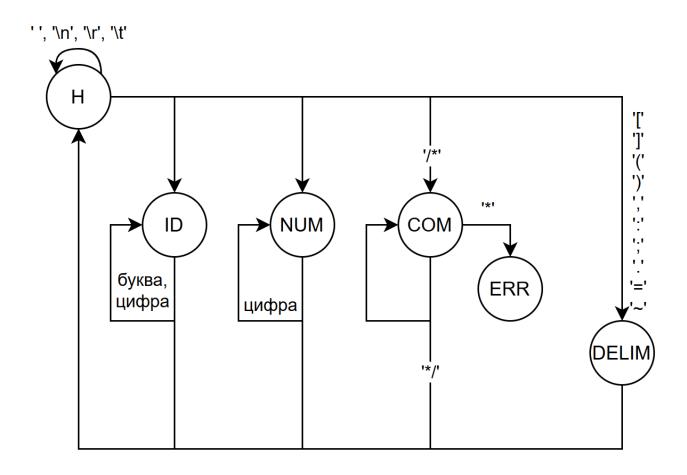


Рисунок 1 – Диаграмма состояний лексического анализатора

#### 5 РАЗРАБОТКА СИНТАКСИЧЕСКОГО АНАЛИЗАТОРА

Будем считать, что лексический и синтаксической анализаторы взаимодействуют следующим образом. Если синтаксическому анализатору для анализа требуется очередная лексема, он запрашивает ее у лексического анализатора. Таким образом, разбор исходного текста программы идет под управлением подпрограммы синтаксического анализатора (parser).

Разработку синтаксического анализатора проведем с помощью метода рекурсивного спуска (РС). В основе метода лежит тот факт, что каждому нетерминалу ставится в соответствие рекурсивная функция. Для того, чтобы в явном виде представить множество рекурсивных функций, перепишем грамматические правила следующим образом:

```
P 
ightharpoonup Program D1; B \perp D1 
ightharpoonup var D \{,D\}
D 
ightharpoonup I \{,I\}:[integer|boolean]
B 
ightharpoonup begin S \{; S\} end.
S 
ightharpoonup I = E | if E then S else S | while E do S | B | read(I) | write(E)
E 
ightharpoonup E1 \{[EQ | GT | LT | GE | LE | NE ]E1\}
E1 
ightharpoonup T\{[+|-|or]T\}
T 
ightharpoonup F\{[*|/|and]F\}
F 
ightharpoonup I | N | L | not F | (E)
L 
ightharpoonup true | false
I 
ightharpoonup C | IC | IR
N 
ightharpoonup R | NR
C 
ightharpoonup a | b | ... | z | A | B | ... | Z
R 
ightharpoonup 0 | 1 | ... | 9
```

Здесь правила для нетерминалов L, I, N, C и R описаны на этапе лексического разбора. Следовательно, остается описать функции для нетерминалов P, D1, D, B, S, E, E1, T, F.

Исходный код синтаксического анализатора приведен в Приложении Б.

# 6 СЕМАНТИЧЕСКИЙ АНАЛИЗ

Некоторые особенности модельного языка не могут быть описаны контекстно-свободной грамматикой. К таким правилам относятся:

- любой идентификатор, используемый в теле программы должен быть описан;
- повторное описание одного и того же идентификатора не разрешается;
- в операторе присваивания типы идентификаторов должны совпадать;
- в условном операторе и операторе цикла в качестве условия допустимы только логические выражения;
  - операнды операций отношения должны быть целочисленными.

Указанные особенности языка разбираются на этапе семантического анализа. Удобно процедуры семантического анализа совместить с процедурами синтаксического анализа. На практике это означает, что в рекурсивные функции встраиваются дополнительные контекстно-зависимые проверки. Например, на этапе лексического анализа в таблицу ТІD заносятся данные обо всех лексемахидентификаторах, которые встречаются в тексте программы. На этапе синтаксического анализа в ту же таблицу заносятся данные о типе идентификатора (поле type) и о наличии для него описания (поле declared).

С учетом сказанного, правила вывода для нетерминала D (раздел описаний) принимают вид:

 $D \rightarrow stack.reset()$  I  $stack.push(c\_val)$  {, I  $stack.push(c\_val)$ } : [integer  $dec(LEX\ INT) \mid boolean\ dec(LEX\ BOOL)$ ]

Здесь stack – структура данных, в которую запоминаются идентификаторы (номера строк в таблице TID), dec – функция, задача которой заключается в занесении информации об идентификаторах (поля type и declared), а также контроль повторного объявления идентификатора.

роль повторного объявления идентификатора. Описания функций семантических проверок приведены в листинге в Приложении Б.

## 7 ТЕСТИРОВАНИЕ ПРОГРАММЫ

В качестве программного продукта разработано консольное приложение parser.exe, Приложение принимает на вход исходный текст программы на модельном языке и выдает в качестве результата сообщение о синтаксической и семантической корректности написанной программы. В случае обнаружения ошибки программа выдает сообщение об ошибке с номером некорректной лексемы. Рассмотрим примеры.

1. Исходный код программы приведен в листинге 1

Листинг 1 - Тестовая программа

```
program
  var
     x, y : integer;
begin
    read(x); /* Вводим значение x */
    y as x;
    while x GT 0 do [
        y as y plus x;
        x as x min 1
    ];
    write(y) /* Выводим результат */
end.
```

Данная программа синтаксически корректна, поэтому анализатор выдает следующее сообщение (рис. 2).

```
main.py
         example.txt M ×
       program
           var
               x, y : integer;
           begin
                read(x); /* Вводим значение x */
                v as x:
                while x GT 0 do [
                    y as y plus x;
                    x as x min 1
                ]:
                write(y) /* Выводим результат */
  12
       end.
            TERMINAL
PS S:\formal_language_theory\language_parser> python -m parser.main
vep
```

Рисунок 2 – Пример синтаксически корректной программы

2. Исходный код программы, содержащий синтаксическую ошибку, приведен на рис. 3 совместно с сообщением об ошибке.

```
program
                x, y : integer;
           begin
                read(x); /* Вводим значение x */
   5
                y as x;
                while x GT 0 do [
                    y as y plus x;
                    x as x min 1
                ];
                write(y) /* Выводим результат */
      end.
PROBLEMS OUTPUT TERMINAL PORTS CODE REFERENCE LOG DEBUG CONSOLE
PS S:\formal_language_theory\language_parser> python -m parser.main
Syntax error at line 2: Expected 'var', found 'x'
    x, y : integer;
```

Рисунок 3 – Пример программы, содержащей синтаксическую ошибку

Здесь ошибка допущена в строке 2: отсутствует ключевое слово **var** перед объявлением переменных.

3. Исходный текст программы, содержащей семантическую проверку, приведен на рис. 4 вместе с сообщением об ошибке. Здесь переменная у объявлена дважды.

```
1 \sim program
           var
   3
               x, y, y : integer;
           begin
               read(x); /* Вводим значение x */
   6
               v as x:
               while x GT 0 do [
                    y as y plus x;
                    x as x min 1
               ]:
               write(y) /* Выводим результат */
      end.
PROBLEMS OUTPUT TERMINAL PORTS CODE REFERENCE LOG DEBUG CONSOLE
PS S:\formal_language_theory\language_parser> python -m parser.main
Syntax error at line 3: Variable 'y' already declared
    x, y, y : integer;
```

Рисунок 4 – Пример программы, содержащей семантическую ошибку

3. Исходный текст программы, содержащей семантическую проверку, приведен на рис. 5 вместе с сообщением об ошибке. Здесь переменная у не объявлена, но используется в коде.

```
example.txt
       program
            var
    3
                 x: integer;
            begin
                 read(x); /* Вводим значение x */
   6
                y as x;
                while x GT 0 do [
                     v as v plus x:
                     x as x min 1
                 1:
                write(y) /* Выводим результат */
       end.
PROBLEMS OUTPUT TERMINAL PORTS CODE REFERENCE LOG DEBUG CONSOLE
•PS S:\formal_language_theory\language_parser> python -m parser.main
Syntax error at line 6: Variable 'y' not declared
    y as x;
```

Рисунок 5 – Пример программы, содержащей семантическую ошибку

### **ЗАКЛЮЧЕНИЕ**

В работе представлены результаты разработки анализатора языка программирования. Грамматика языка задана с помощью правил вывода и описана в форме Бэкуса-Наура (БНФ). Согласно грамматике, в языке присутствуют лексемы следующих базовых типов: числовые константы, переменные, разделители и ключевые слова.

Разработан лексический анализатор, позволяющий разделить последовательность символов исходного текста программы на последовательность лексем. Лексический анализатор реализован на языке высокого уровня Python в виде класса Lexer.

Разбором исходного текста программы занимается синтаксический анализатор, который реализован в виде класса Parser на языке Python. Анализатор распознает входной язык по методу рекурсивного спуска. Для применимости необходимо было преобразовать грамматику, в частности, специальным образом обрабатывать встречающиеся итеративные синтаксически конструкции.

В код рекурсивных функций включены проверки дополнительных семантических условий, в частности, проверка на повторное объявление одной и той же переменной.

Тестирование программного продукта показало, что синтаксически и семантически корректно написанная программа успешно распознается анализатором, а программа, содержащая ошибки, отвергается.

В работы изучены ходе основные принципы построения интеллектуальных систем на основе теории автоматов и формальных приобретены грамматик, навыки лексического, синтаксического И семантического анализа предложений языков программирования.

## СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

- 1. Свердлов С. 3. Языки программирования и методы трансляции: учебное пособие. Санкт-Петербург: Лань, 2019.
- 2. Малявко А. А. Формальные языки и компиляторы: учебное пособие для вузов. М.: Юрайт, 2020.
- 3. Миронов С. В. Формальные языки и грамматики: учебное пособие для студентов факультета компьютерных наук и информационных технологий. Саратов: СГУ, 2019.
- 4. Унгер А.Ю. Основы теории трансляции: учебник. М.: МИРЭА Российский технологический университет, 2022.
- 5. Антик М. И., Казанцева Л. В. Теория формальных языков в проектировании трансляторов: учебное пособие. М.: МИРЭА, 2020.
- 6. Ахо А. В., Лам М. С., Сети Р., Ульман Дж. Д. Компиляторы: принципы, технологии и инструментарий. М.: Вильямс, 2008.
- 7. Ишакова Е.Н. Теория языков программирования и методов трансляции: учебное пособие. Оренбург: ИПК ГОУ ОГУ, 2007

# приложения

Приложение А – Класс лексического анализатора

Приложение Б – Класс синтаксического анализатора

#### Приложение А

#### Класс лексического анализатора

#### Листинг A.1 - Lexer.py

```
class Token:
    def init (self, table num, lexeme num, line, column, value=None):
        self.table num = table num # n
       self.lexeme num = lexeme num # k
       self.line = line
       self.column = column
        self.value = value
    def str _(self):
        return f"({self.table num}, {self.lexeme num}): {self.value}"
class Lexer:
    def __init__(self, text):
        self.text = text
        self.pos = 0
        self.line = 1
        self.column = 1
        self.current char = self.text[self.pos] if self.pos < len(self.text)</pre>
else None
        self.tokens = []
        self.text lines = self.text.split("\n")
        # Таблица служебных слов (n = 1)
        self.keywords table = [
            "program",
            "var",
            "begin",
            "end",
            "if",
            "else"
            "while",
            "for",
            "to",
            "then",
            "do",
            "read",
            "write",
            "true",
            "false",
            "integer",
            "real",
            "boolean",
            "as",
        ]
        \# Таблица операторов отношений (n = 2)
        self.rel op table = ["NE", "EQ", "LT", "LE", "GT", "GE"]
        # Таблица операций сложения (n = 3)
        self.add_ops_table = ["plus", "min", "or"]
        # Таблица операций умножения (n = 4)
        self.mul ops table = ["mult", "div", "and"]
        # Таблица унарных операций (n = 5)
        self.uops table = ["~"]
```

```
# Таблица разделителей (n = 6)
        self.delimiters table = ["[", "]", "(", ")", ",", ":", ";", ".", "=",
"<", ">"]
        \# Таблица для чисел (n = 7)
        self.numbers table = []
        # Таблица для идентификаторов (n = 8)
        self.identifiers table = []
    def advance(self):
        """Переход к следующему символу."""
        if self.current char == "\n":
            self.line += 1
            self.column = 1
        else:
            self.column += 1
        self.pos += 1
        if self.pos < len(self.text):</pre>
            self.current char = self.text[self.pos]
        else:
            self.current char = None
    def add token(self, n, k, value=None):
        """Добавление токена в список токенов."""
        self.tokens.append(
            Token(n, k, self.line, self.column - (len(value) if value else 0),
value)
    def skip whitespace(self):
        """Пропуск пробельных символов."""
        while self.current char and self.current char.isspace():
            self.advance()
    def parse identifier or keyword(self):
        """Разбор идентификаторов и ключевых слов."""
        start = self.pos
        while self.current char and (
            self.current char.isalnum() or self.current char == " "
        ):
            self.advance()
        text = self.text[start : self.pos]
        # Проверяем, является ли текст служебным словом
        if text.lower() in self.keywords table:
            self.add token(1, self.keywords table.index(text.lower()) + 1,
value=text)
        # Проверяем, является ли текст оператором отношений
        elif text.upper() in self.rel op table:
            self.add token(2, self.rel_op_table.index(text.upper()) + 1,
value=text)
        # Проверяем, является ли текст операцией сложения
        elif text.lower() in self.add ops table:
            self.add token(3, self.add ops table.index(text.lower()) + 1,
value=text)
        # Проверяем, является ли текст операцией умножения
        elif text.lower() in self.mul ops table:
            self.add_token(4, self.mul_ops_table.index(text.lower()) + 1,
value=text)
```

```
else:
            # Иначе считаем текст идентификатором
            if text not in self.identifiers table:
                self.identifiers_table.append(text)
            self.add token(8, self.identifiers table.index(text) + 1,
value=text)
    def parse number(self):
        """Разбор числовых литералов, включая поддержку суффиксов."""
        text = ""
        has_decimal_point = False
        is \overline{float} = \overline{False}
        while self.current char and (self.current char.isdigit() or
self.current char.upper() in 'ABCDEF' or self.current_char == '.'):
            if self.current char == '.':
                if has decimal point:
                    # Две десятичные точки - считаем за идентификатор
                    is float = False
                    break
                has decimal point = True
                is float = True
            text += self.current char
            self.advance()
        if self.current char and self.current char.upper() == 'E':
            is float = True
            text += self.current char
            self.advance()
            if self.current char in '+-':
                text += self.current char
                self.advance()
            if self.current char and self.current char.isdigit():
                while self.current char and self.current char.isdigit():
                    text += self.current char
                    self.advance()
            else:
                is_float = False
        suffix = ""
        if self.current char and self.current char.lower() in 'bohd':
            suffix = self.current char.lower()
            text += self.current char
            self.advance()
        # Если после числа идет буква, и это не суффикс системы счисления, то
это идентификатор
        if self.current char is not None and self.current char.isalpha() and
len(suffix) != 1:
            while self.current char is not None and self.current char.isalnum():
                text += self.current char
                self.advance()
            if text not in self.identifiers table:
                self.identifiers table.append(text)
            self.add token(8, self.identifiers table.index(text) + 1,
value=text)
            return
        if text not in self.numbers table:
            self.numbers table.append(text)
```

```
self.add token(7, self.numbers table.index(text) + 1, value=text)
    def parse comment(self):
        """Разбор комментариев вида /* ... */."""
        self.advance() # Пропускаем '/'
        self.advance() # Пропускаем '*'
        while self.current char:
            if self.current char == "*":
                self.advance()
                if self.current char == "/":
                    self.advance()
                    return
                else:
                    raise Exception (
                        f"Syntax error at line {self.line}: An incomplete
multi-line comment\n
                        {self.text lines[self.line - 1].strip()}"
            else:
                self.advance()
    def parse delimiter or operator(self):
        """Разбор разделителей и операторов."""
        char = self.current char
        self.advance()
        text = char
        # Проверка на многосимвольные операторы
        if char == "<" and self.current char == "=":
            text += self.current char
            self.advance()
        elif char == ">" and self.current_char == "=":
            text += self.current char
            self.advance()
        elif char == "a" and self.current_char == "s":
            text += self.current char
            self.advance()
        # Определение типа токена
        if text.upper() in self.rel op table:
            self.add token(2, self.rel op table.index(text.upper()) + 1,
value=text)
        elif text.lower() in self.add ops table:
            self.add token(3, self.add ops table.index(text.lower()) + 1,
        elif text.lower() in self.mul ops table:
            self.add token(4, self.mul ops table.index(text.lower()) + 1,
value=text)
        elif text in self.uops table:
            self.add_token(5, self.uops table.index(text) + 1, value=text)
        elif text in self.delimiters table:
            self.add_token(6, self.delimiters_table.index(text) + 1, value=text)
        else:
            self.add token(0, 0, value=text) # Неизвестный токен
    def tokenize(self):
        """Основной метод лексического анализа."""
        while self.current char:
            self.skip_whitespace()
            if not self.current char:
                break
```

Продолжение листинга А.1

```
if self.current_char == "/" and self.peek() == "*":
                self.parse comment()
            elif self.current char.isalpha() or self.current char == " ":
                self.parse identifier or keyword()
            elif self.current char.isdigit():
                self.parse_number()
            elif self.current_char in self.delimiters_table or self.current_char
in [
                "<",
                ">",
                ":",
                "!",
                "=",
                "~",
                "+",
                "-",
                "*",
                "/",
                "a",
            1:
                self.parse delimiter or operator()
                # Неизвестный символ, можно обработать как ошибку или пропустить
                self.add token(0, 0, value=self.current char)
                self.advance()
        self.add_token(0, 0, "EOF") # Добавляем токен конца файла
        return self.tokens
    def peek(self):
        """Вспомогательный метод для просмотра следующего символа без его
извлечения."""
        if self.pos + 1 < len(self.text):</pre>
            return self.text[self.pos + 1]
        else:
            return None
```

#### Приложение Б

#### Класс синтаксического анализатора

#### Листинг Б.1 - Parser.py

```
class SymbolTable:
    def init (self):
        \overline{\text{self.symbols}} = \{\}
        self.scopes = []
    def enter scope(self):
        """Вход в новую область видимости."""
        self.scopes.append({})
    def exit scope(self):
        """Выход из текущей области видимости."""
        self.scopes.pop()
    def define(self, name, type):
        """Определить переменную в текущей области видимости."""
        current scope = self.scopes[-1]
        if name in current scope:
            return False # Переменная уже определена в этой области видимости
        current scope[name] = type
        return True
    def lookup(self, name):
        """Найти переменную в таблице символов."""
        for scope in reversed(self.scopes):
            if name in scope:
                return scope[name]
        return None
class Parser:
    def init (self, lexer):
        \overline{\text{self.lexer}} = \text{lexer}
        self.tokens = lexer.tokenize() # Получаем список токенов сразу
        self.current token index = 0
        self.current token = (
            self.tokens[self.current token index] if self.tokens else None
        )
        self.symbol table = SymbolTable()
        self.text lines = lexer.text.split("\n")
        # Словари для быстрого доступа к номерам лексем по их именам
        self.keywords dict = {
            name: i + 1 for i, name in enumerate(lexer.keywords table)
        self.rel op dict = {name: i + 1 for i, name in
enumerate(lexer.rel op table) }
        self.add ops dict = {name: i + 1 for i, name in
enumerate(lexer.add ops table)}
        self.mul ops dict = {name: i + 1 for i, name in
enumerate(lexer.mul_ops_table)}
        self.uops dict = {name: i + 1 for i, name in
enumerate(lexer.uops table)}
        self.delimiters dict = {
            name: i + 1 for i, name in enumerate(lexer.delimiters table)
```

```
def advance(self):
       """Переход к следующему токену."""
       self.current token index += 1
       if self.current token index < len(self.tokens):</pre>
           self.current token = self.tokens[self.current token index]
       else:
           self.current token = None
   def error(self, message, context=None):
       line = self.text_lines[self.current_token.line - 1]
       stript line = line.strip()
       if context:
           message = f"In rule '{context}', " + message
       raise Exception(
           f"Syntax error at line {self.current token.line}: {
               message}\n {stript line}"
       )
   def get token name(self, token):
        значению."""
       if token.table num == 0:
           return token.value
       if token.table num == 1:
               return self.lexer.keywords table[token.lexeme num - 1]
           except IndexError:
               return "unknown keyword"
       elif token.table num == 2:
               return self.lexer.rel op table[token.lexeme num - 1]
           except IndexError:
               return "unknown rel op"
       elif token.table num == 3:
           try:
               return self.lexer.add ops table[token.lexeme num - 1]
           except IndexError:
               return "unknown add op"
       elif token.table num == 4:
               return self.lexer.mul ops table[token.lexeme num - 1]
           except IndexError:
               return "unknown mul op"
       elif token.table num == 5:
           try:
               return self.lexer.uops table[token.lexeme num - 1]
           except IndexError:
               return "unknown uop"
       elif token.table num == 6:
               return self.lexer.delimiters table[token.lexeme num - 1]
           except IndexError:
               return "unknown delimiter"
       elif token.table num in (7, 8):
           return token.value # Для чисел и идентификаторов выводим их
значение
       else:
           return f"({token.table num}, {token.lexeme num})"
   def eat(self, table num, lexeme num):
           self.current token.table num == table num
```

```
):
            self.advance()
        else:
            # Поиск имени токена для вывода ошибки:
            if table num == 1:
                expected token name = (
                     self.lexer.keywords_table[lexeme_num - 1]
                     if lexeme num - 1 < len(self.lexer.keywords table)</pre>
                    else "unknown keyword"
                )
            elif table num == 2:
                expected token name = (
                     self.lexer.rel_op_table[lexeme_num - 1]
                     if lexeme_num - 1 < len(self.lexer.rel_op_table)</pre>
                    else "unknown rel op"
                )
            elif table num == 3:
                expected token name = (
                    self.lexer.add_ops_table[lexeme_num - 1]
                     if lexeme num - 1 < len(self.lexer.add ops table)
                    else "unknown add op"
                )
            elif table num == 4:
                expected token name = (
                    self.lexer.mul ops table[lexeme num - 1]
                    if lexeme num - 1 < len(self.lexer.mul_ops_table)</pre>
                    else "unknown mul op"
            elif table_num == 5:
                expected token name = (
                    self.lexer.uops table[lexeme num - 1]
                    if lexeme num - 1 < len(self.lexer.uops table)
                    else "unknown uop"
            elif table num == 6:
                expected token name = (
                    self.lexer.delimiters table[lexeme num - 1]
                    if lexeme num - 1 < len(self.lexer.delimiters_table)</pre>
                    else "unknown delimiter"
            else:
                expected token name = f"({table num}, {lexeme num})"
            current token name = self.get token name(self.current token)
            if (table num, lexeme num) == (
                6,
                self.delimiters dict[";"],
            ):
                # Если ожидался конец составного оператора, но нашелся другой
разделитель, указываем на него
                self.error(
                     f"Expected '{expected token name}', found
'{current token name}'"
            else:
                self.error(
                     f"Expected '{expected token name}', found
'{current_token_name}'"
```

```
def program(self):
        <программа> ::= program var <описание> begin <оператор> {; <оператор>}
end.
        self.eat(1, self.keywords dict["program"])
        self.eat(1, self.keywords_dict["var"])
        self.symbol table.enter scope() # Входим в глобальную область видимости
        self.description()
        self.eat(1, self.keywords dict["begin"])
        self.operator_list()
        self.eat(1, self.keywords_dict["end"])
        self.eat(6, self.delimiters_dict["."])
        self.symbol table.exit scope()
                                       # Выходим из глобальной области
видимости
        if not (
            self.current token.table num == 0 and self.current token.lexeme num
== 0
        ):
            self.error("Expected end of program")
    def operator list(self):
        <oneparop> {; <oneparop>}
        self.operator ()
        while (
            self.current token.table num == 6
            and self.current token.lexeme num == self.delimiters dict[";"]
        ):
            self.eat(6, self.delimiters dict[";"])
                self.current token.table num == 1
                and self.current token.lexeme num == self.keywords dict["end"]
                return # Обрабатываем END
            self.operator ()
    def description(self):
        <oписание> ::= {<идентификатор> {, <идентификатор>} : <тип> ;}
        while self.current token.table num == 8:
            ids = self.id list()
            self.eat(6, self.delimiters dict[":"])
            type token = self.type()
            for id token in ids:
                if not self.symbol table.define(id token.value, type token):
                    self.error(f"Variable '{id token.value}' already declared")
            self.eat(6, self.delimiters_dict[";"])
    def id list(self):
        <идентификатор> {, <идентификатор>}
        id tokens = [self.current token]
        if not self.current token.value[0].isalpha():
            self.error(
```

```
f"Identifier '{self.current_token.value}' must start with a
letter",
                context="id list",
            )
        self.eat(8, self.current token.lexeme num)
        while (
            self.current_token.table_num == 6
            and self.current token.lexeme num == self.delimiters dict[","]
        ):
            self.eat(6, self.delimiters dict[","])
            id tokens.append(self.current token)
            if not self.current token.value[0].isalpha():
                self.error(
                    f"Identifier '{self.current token.value}' must start with a
letter",
                    context="id list",
            self.eat(8, self.current token.lexeme num)
        return id tokens
    def type(self):
        <тип> ::= integer | real | boolean
        if (
            self.current token.table num == 1
            and self.current_token.lexeme_num == self.keywords_dict["integer"]
            type token = self.current token
            self.eat(1, self.keywords dict["integer"])
           return type token
        elif (
            self.current token.table num == 1
            and self.current_token.lexeme_num == self.keywords_dict["real"]
        ):
            type token = self.current token
            self.eat(1, self.keywords_dict["real"])
            return type token
        elif (
            self.current token.table num == 1
            and self.current token.lexeme num == self.keywords dict["boolean"]
            type token = self.current token
            self.eat(1, self.keywords dict["boolean"])
            return type token
            self.error("Expected type (integer, real, boolean)")
    def operator (self):
        <оператор> ::= <присваивания> | <условный> | <фиксированного цикла> |
<условного цикла> | <составной> | <ввода> | <вывода>
        if self.current_token.table_num == 8:
            self.assignment()
        elif (
            self.current_token.table_num == 1
            and self.current token.lexeme num == self.keywords dict["if"]
        ):
            self.conditional()
        elif (
            self.current token.table num == 1
```

```
and self.current token.lexeme num == self.keywords dict["for"]
        ):
            self.fixed loop()
        elif (
            self.current token.table num == 1
            and self.current token.lexeme num == self.keywords dict["while"]
        ):
            self.conditional loop()
        elif (
            self.current token.table num == 6
            and self.current token.lexeme num == self.delimiters dict["["]
            self.compound()
        elif (
            self.current token.table num == 1
            and self.current token.lexeme num == self.keywords dict["read"]
            self.input_op()
        elif (
            self.current token.table num == 1
            and self.current token.lexeme num == self.keywords dict["write"]
            self.output op()
        else:
            self.error("Expected operator")
    def assignment(self):
        <присваивания> ::= <идентификатор> as <выражение>
        id token = self.current token
        self.eat(8, self.current token.lexeme num)
        if not self.symbol table.lookup(id token.value):
            self.error(f"Variable '{id token.value}' not declared")
        self.eat(1, self.keywords_dict["as"])
        self.expression()
    def conditional(self):
        <yсловный> ::= if <выражение> then <оператор> [ else <оператор>]
        self.eat(1, self.keywords dict["if"])
        self.expression()
        self.eat(1, self.keywords dict["then"])
        self.operator ()
            self.current token.table num == 1
            and self.current token.lexeme num == self.keywords dict["else"]
        ):
            self.eat(1, self.keywords dict["else"])
            self.operator ()
    def fixed loop(self):
        <фиксированного цикла> ::= for <присваивания> to <выражение> do
<оператор>
        self.eat(1, self.keywords dict["for"])
        self.symbol table.enter scope() # Входим в область видимости цикла
        self.assignment()
        self.eat(1, self.keywords dict["to"])
        self.expression()
```

```
self.eat(1, self.keywords dict["do"])
        self.operator ()
        self.symbol table.exit scope() # Выходим из области видимости цикла
    def conditional loop(self):
        <ycловного цикла> ::= while <выражение> do <oператор>
       self.eat(1, self.keywords dict["while"])
       self.expression()
        self.eat(1, self.keywords dict["do"])
        self.operator ()
    def compound(self):
        <cocтавной> ::= «[» <oператор> { ( : | \n) <oператор> } «]»
        self.eat(6, self.delimiters dict["["])
       self.symbol table.enter scope() # Входим в область видимости составного
оператора
       self.operator ()
       while self.current token.table num == 6 and (
            self.current token.lexeme num == self.delimiters dict[":"]
            or self.current token.lexeme num == self.delimiters dict[";"]
        ):
            if self.current token.lexeme num == self.delimiters dict[";"]:
                self.eat(6, self.delimiters dict[";"])
            else:
                self.eat(6, self.delimiters dict[":"])
            self.operator ()
        if (
            self.current token.table num != 6
            or self.current token.lexeme num != self.delimiters dict["]"]
        ):
            self.error(
                f"Expected ']', found
'{self.get_token_name(self.current token)}'",
                context="compound",
            )
        self.symbol table.exit scope()
                                        # Выходим из области видимости
составного оператора
        self.eat(6, self.delimiters dict["]"])
    def input_op(self):
        <ввода> ::= read «(»<идентификатор> {, <идентификатор> } «)»
        self.eat(1, self.keywords dict["read"])
        self.eat(6, self.delimiters dict["("])
        id_token = self.current_token
        self.eat(8, self.current token.lexeme num)
        if not self.symbol_table.lookup(id_token.value):
            self.error(f"Variable '{id token.value}' not declared")
        while (
            self.current_token.table_num == 6
            and self.current_token.lexeme_num == self.delimiters_dict[","]
        ):
            self.eat(6, self.delimiters dict[","])
            id token = self.current token
            self.eat(8, self.current_token.lexeme_num)
            if not self.symbol table.lookup(id token.value):
```

```
self.error(f"Variable '{id_token.value}' not declared")
    self.eat(6, self.delimiters dict[")"])
def output op(self):
    <вывода> ::= write «(»<выражение> {, <выражение> } «)»
    self.eat(1, self.keywords_dict["write"])
    self.eat(6, self.delimiters dict["("])
    self.expression()
   while (
        self.current token.table num == 6
       and self.current token.lexeme num == self.delimiters dict[","]
       self.eat(6, self.delimiters dict[","])
        self.expression()
    self.eat(6, self.delimiters dict[")"])
def expression(self):
    <выражение> ::= <сумма> | <выражение> (<>|=|<|<=|>|>=) <сумма>
    self.sum()
   while self.current token.table num == 2:
        if self.current token.lexeme num == self.rel op dict["NE"]:
            self.eat(2, self.rel_op_dict["NE"])
        elif self.current_token.lexeme_num == self.rel_op_dict["EQ"]:
            self.eat(2, self.rel_op_dict["EQ"])
        elif self.current token.lexeme num == self.rel op dict["LT"]:
            self.eat(2, self.rel op dict["LT"])
        elif self.current token.lexeme num == self.rel op dict["LE"]:
            self.eat(2, self.rel op dict["LE"])
        elif self.current token.lexeme num == self.rel op dict["GT"]:
            self.eat(2, self.rel_op_dict["GT"])
        elif self.current_token.lexeme_num == self.rel_op_dict["GE"]:
            self.eat(2, self.rel_op_dict["GE"])
        else:
            break
        self.sum()
def sum(self):
    <cyмма> ::= <произведение> { (+ | - | or) <произведение>}
    self.product()
    while self.current token.table num == 3:
        if self.current_token.lexeme_num == self.add ops dict["plus"]:
            self.eat(3, self.add ops dict["plus"])
        elif self.current token.lexeme num == self.add ops dict["min"]:
            self.eat(3, self.add ops dict["min"])
        elif self.current_token.lexeme_num == self.add_ops dict["or"]:
            self.eat(3, self.add ops dict["or"])
        else:
            break
        self.product()
def product(self):
    <произведение> ::= <множитель> { (* | / | and) <множитель>}
```

```
self.multiplier()
        while self.current token.table num == 4:
            if self.current token.lexeme num == self.mul ops dict["mult"]:
                self.eat(4, self.mul ops dict["mult"])
            elif self.current token.lexeme num == self.mul ops dict["div"]:
                self.eat(4, self.mul_ops_dict["div"])
            elif self.current_token.lexeme_num == self.mul_ops_dict["and"]:
                self.eat(4, self.mul_ops_dict["and"])
            else:
                break
            self.multiplier()
   def multiplier(self):
        <множитель> ::= <идентификатор> | <число> | <логическая константа> | not
<множитель> | «(»<выражение>«)»
        if self.current token.table num == 8:
            id token = self.current token
            self.eat(8, self.current token.lexeme num)
            if not self.symbol table.lookup(id token.value):
                self.error(f"Variable '{id token.value}' not declared")
        elif self.current token.table num == 7:
           self.number()
        elif self.current_token.table_num == 1 and (
           self.current token.lexeme num == self.keywords dict["true"]
            or self.current token.lexeme num == self.keywords dict["false"]
        ):
            self.logical constant()
        elif (
            self.current token.table num == 5
            and self.current token.lexeme num == self.uops dict["~"]
            self.eat(5, self.uops_dict["~"])
            self.multiplier()
        elif (
            self.current token.table num == 6
            and self.current token.lexeme num == self.delimiters dict["("]
            self.eat(6, self.delimiters dict["("])
            self.expression()
            self.eat(6, self.delimiters dict[")"])
        else:
            self.error("Expected identifier, number, logical constant, 'not', or
'('")
   def number (self):
        <число> ::= <целое> | <действительное>
        if self.current token.table num == 7:
           number_token = self.current token
            number_value = number_token.value
            self.eat(7, self.current_token.lexeme_num)
            if (
                number value.endswith("b")
                and number value.startswith("0")
                and len(number value) > 2
            ):
```

```
self.error(f"Invalid binary number '{number value}'",
context="number")
            elif (
                number value.endswith("o")
                and number value.startswith("0")
                and len(number value) > 2
            ):
                self.error(f"Invalid octal number '{number_value}'",
context="number")
            elif (
                number value.endswith("h")
                and number value.startswith("0")
                and len(number value) > 2
            ):
                self.error(
                    f"Invalid hexadecimal number '{number value}'",
context="number"
            elif (
                number value.endswith("d")
                and number value.startswith("0")
                and len(number value) > 2
            ):
                self.error(f"Invalid decimal number '{number value}'",
context="number")
            elif any(
                c not in "01" for c in number value[:-1]
            ) and number value.endswith("b"):
                self.error(f"Invalid binary number '{number value}'",
context="number")
            elif any(
                c not in "01234567" for c in number value[:-1]
            ) and number value.endswith("o"):
                self.error(f"Invalid octal number '{number_value}'",
context="number")
            elif any(
                c not in "0123456789abcdefABCDEF" for c in number value[:-1]
            ) and number value.endswith("h"):
                self.error(
                    f"Invalid hexadecimal number '{number value}'",
context="number"
            elif any(
                c not in "0123456789" for c in number value[:-1]
            ) and number value.endswith("d"):
                self.error(f"Invalid decimal number '{number_value}'",
context="number")
            elif any(c not in "0123456789.eE+-" for c in number value) and (
                "e" in number value or "E" in number value or "." in
number value
            ):
                self.error(f"Invalid float number '{number_value}'",
context="number")
            elif (
                any(c not in "0123456789" for c in number_value)
                and not (
                    "e" in number value or "E" in number value or "." in
number value
                and (number value[-1] not in "bohd")
            ):
```

```
self.error(f"Invalid decimal number '{number_value}'",
context="number")
        else:
            self.error("Expected number")
    def logical_constant(self):
        <логическая_константа> ::= true | false
        if (
            self.current token.table num == 1
            and self.current token.lexeme num == self.keywords dict["true"]
            self.eat(1, self.keywords dict["true"])
        elif (
            self.current token.table num == 1
            and self.current token.lexeme num == self.keywords dict["false"]
            self.eat(1, self.keywords dict["false"])
        else:
            self.error("Expected 'true' or 'false'")
    def parse(self):
        """Запуск синтаксического анализа."""
        self.program()
        if not (
            self.current_token.table_num == 0 and self.current_token.lexeme_num
== 0
        ):
            self.error("Expected end of program")
```